Pontificia Universidad Católica de Chile
Instituto de Ingeniería Matemática y Computacional 2026-2

IMT2220

Cálculo para Ciencia de Datos

Tarea Computacional

Grupo 10

INTEGRANTES
Lucas Martín Chicao Carmona
Ignacio Andrés Osorio Orellana
Martín Ignacio Serrano Pizarro
Martin Antonio Von Gehr Campos

Profesor
Eduardo Cerpa
eduardo.cerpa@uc.cl

Ayudante
Kevin Cardemil
kevin.cardemil@uc.cl

PROBLEMA 1

Reconstrucción de una imagen

(a) Mínimos cuadrados

i. **Gradiente y matriz Hessiana de J_0.**

El enunciado nos dice que consideremos $J_0(x) = \|Ax - b\|_2^2$. Podemos comenzar calculando el gradiente

Asi tenemos lo siguiente:

$J_0(x) = \|Ax - b\|_2^2$ = $(Ax - b)^T * (Ax - b)$ = $(x^T A^T - b^T) * (Ax - b)$ = $x^T A^T Ax - b^T Ax - b^T b$

Ahora como x y b son vectores en R^n (especificamente n x 1, y 1 x n para x^T) y A es n x n podemos notar que $x^T A^T b$ es un escalar ((1 x n) * (n x n) * (n x 1)). Por ende es igual a su transpuesta, asi:

$x^T A^T b = b^T Ax$

Entonces $J_0(x) = x^T A^T Ax - 2b^T Ax + b^T b$

Ahora buscamos el gradiente de la funcion, aplicamos $\nabla J_0(x)$, Derivando cada termino:

- La regla para la siguiente forma $\nabla x(x^T Mx)$ = $(M + M^T)x$

Usando ahora $M = A^T A \rightarrow M^T = A^T (A^T)^T$ = A^T entonces :

$\nabla x(x^T A^T x) = (A^T + A^T) = 2A^T Ax$

-Derivada para $-2(b^T Ax)$, podemos notar que $-2(b^T Ax) = -2(A^T b)^T x$ con ello tenemos la forma $c^T x$; $\nabla x(c^T x) = c$

Entonces :

$\nabla x(-2(A^T b)^T x) = -2(A^T b)$

- Como $b^T b$ No depende de x; $\nabla x(b^T b) = 0$

Asi tenemos que $\nabla x J_0(x)$ = $2A^T Ax - 2A^T b$

Ahora para la Matriz Hessiana se parte del $\nabla J_0(x)$ anterior;

Basicamente debemos calcular $H_{J_0}(x) = \nabla x(\nabla J_0(x))$ asi :

- $\nabla x(2A^T Ax) \rightarrow 2A^T A$ - $-2A^T b$ no tiene un x asi que $\nabla x(-2A^T b) = 0$

Por ende $H_{J_0}(x) = 2A^T A$

Ahora debemos buscar los puntos Criticos y por Teorema de Fernat, el cual nos dice que los puntos criticos de J_0 se encuentran igualando a cero el gradiente.

$\nabla J_0(x) = 0 \Leftrightarrow 2A^T Ax - 2A^T b = 0$ Asi

$A^T Ax = A^T b$

Asi queda demostrado que los puntos criticos de $J_0(x)$ son las ecuaciones normales

$A^T Ax = A^T b$

asd

ii. H_{J_0} **es semidefinida positiva y todo punto crítico es un mínimo global.**

Si todos los valores propios de A^TA son "estrictamente positivos" entonces A^TA es una matriz "Definida positiva"y de rango completo por ende, esta matriz es invertible.

En este caso, el sistema de ecuaciones normales

$A^TAx = A^Tb$ Tiene una unica solucion

$x = (A^TAx)^{-1} * A^Tb$

Por ende J_0 tiene un unico minimizador.

Ahora si A^TA tiene un unico valor propio igual a cero, su determinante es cero haciendo que la matriz no sea invertible.

Ahora digamos que existe un unico vector propio $v \neq 0$ tal que $A^TAv = 0$ (Lo cual implica que Av = 0)

Dado que el sistema de $A^TAx = A^Tb$ siempre mantiene la proyeccion de b, si $< a >$ es un punto critico, cualquier otro punto con la forma $< a + \alpha * v >$ tambien sera una solucion:

$A^TA(\alpha * v) = A^TAxa + \alpha A^TAv = A^Tb + 0 = A^Tb$

Por ende el sistema tiene infinitas soluciones y J_0 tiene infinitos minimizadores.

iii. **Unicidad o infinitos minimizadores.**

Para poder saber si $H_{J_0} = 2A^TA$ es semidefinida positiva ase debe evaluar $\forall v \in \mathbb{R} : v^T * H_{J_0} * v$

Asi para un $v \in \mathbb{R}$:

$v^T(2A^TA)v = 2(Av)^T = 2* \|Av\|_2^2$

y como la norma de cualquier vector es positiva o cero podemos decir que :

$2\|Av\|_2^2 \geq 0$

Por lo tanto H_{J_0} es demidefinida positiva.

Ahora como J_0 es polinomio de grado 2, su aproximacion de taylor de segundo orden es :

$J_0(x+h) = J_0(x) + \nabla J_0(x)^T * h + (h^T * H_{J_0} * h)/2$

si usamos un punto critico tenemos que $\nabla J_0(a) = 0$ asi mismo

$J_0(a+h) = J_0(a) + \nabla J_0(a)^T * h + (h^T * 2A^TA * h)/2$

$J_0(a+h) = J_0(a) + 0 + (h^T * 2A^TA * h)/2$

$J_0(a+h) = J_0(a) + \|Ah\|_2^2$

Como $\|Ah\|_2^2 \geq 0$ para todo h, se puede concluir que $J_0(a+h) \geq J_0(a), \forall h \in \mathbb{R}$.

Asi queda demostrado que a es un minimo absoluto.

.

.

(b) Reconstrucción

i. **Implementación.** Reporten $\|x_0\|_2$, $\max_i |x_{0,i}|$ y $\|Ax_0 - b\|_2$, muestren lado a lado b y x_0, y respondan las preguntas.

Norma ||x0||_2: 350302.18

Máximo absoluto max_i |x0_i|: 1.87e+04

Residuo ||A x0 - b||_2: 5.57e-12

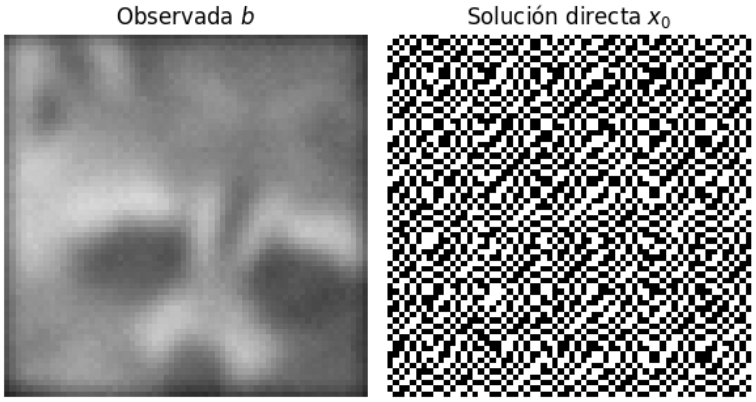


Figura 1: Imagen observada b y solución directa x_0.

La solucion de x_0 No se parece ni de cerca a la imagen de b. Claramente hay mucho ruido y la norma es muchisemo mas grande que el maximo teorico presentado en el enunciado ($n = \sqrt{64}$)

ii. **Explicación.**

Sabemos que por la parte $a)$ de esta pregunta, que el x_0 satisface las ecuaciones normales: $A^T A x_0 = A^T b$

Asi, reemplazando la observacion $b = Ax^* + \eta$ logramos obtener lo siguiente :

$A^T A x_0 = A^T (Ax^* + \eta)$

$A^T A x_0 - A^T A x^* = A^T * \eta$

$A^T A (x_0 - x^*) = A^T * \eta$

Ahora, tomamos el producto interno con el v_i para ambos lados, quedando lo siguiente :

$\langle A^T A (x_0 - x^*), v_i \rangle = \langle A^T \eta, v_i \rangle$

Usando la propiedad de la transpuesta en un producto interno $\langle Mu, w \rangle = \langle u, M^T w \rangle$ y sabiendo que $A^T A$ es simetrica entonces:

$\langle (x_0 - x^*), A^T A v_i \rangle = \langle \eta, A^T v_i \rangle$

Dado que v_i es un vector propio de $A^T A$ con un valor propio de μ_i, sabemos que $A^T A v_i = \mu_i v_i$ y por lo tanto podemos reemplazar

$\langle (x_0 - x^*), \mu_i v_i \rangle = \langle \eta, A^T v_i \rangle$

Por linealidad, sabemos que el escalar sale del producto interno y al divir por μ_i llegamos a lo siguiente:

$\langle (x_0 - x^*), v_i \rangle = \frac{\langle A v_i, \eta \rangle}{\mu_i}$

Ahora partiendo desde ahi, si aplicamos un valor absoluto

$|\langle (x_0 - x^*), v_i \rangle| = |\frac{\langle Av_i, \eta \rangle}{\mu_i}|$

y como por enunciado todo los μ_i son positivos, nos queda lo siguiente:

$\frac{|\langle Av_i, \eta \rangle|}{\mu_i}$

Ahora desde $\langle Av_i, \eta \rangle$ usando la desigualdad de Cauchy-Schwarz tenemos lo siguiente :

$\langle Av_i, \eta \rangle \leq \|Av_i\|_2 \|\eta\|_2$

Para poder calcular el $\|Av_i\|_2$ tenemos que elevarlo al cuadrado y usando las propiedades del producto interno logramos lo siguiente:

$\|Av_i\|_2^2 = \langle Av_i, Av_i \rangle = \langle v_i, A^T Av_i \rangle = \langle v_i, \mu_i v_i \rangle = \mu_i \langle v_i, v_i \rangle = \mu_i \|Av_i\|_2^2$

Ahora dado que los vectores propios v_i son ortonormales, su norma es $\|v_i\|_2 = 1$ Por lo tanto :

$\|Av_i\|_2^2 = \mu_i$

$\|Av_i\|_2 = \sqrt{\mu_i}$

Ahora nomas reemplazamos por lo inicial ($\langle Av_i, \eta \rangle$) y nos queda lo siguiente:

$\langle Av_i, \eta \rangle \leq \sqrt{\mu_i} \|\eta\|_2$

Finalmente solo se tiene que sustituir :

$\langle (x_0 - x^*), v_i \rangle \leq \frac{\sqrt{\mu_i} \|\eta\|_2}{\mu_i}$

$\langle (x_0 - x^*), v_i \rangle \leq \frac{\|\eta\|_2}{\sqrt{\mu_i}}$

Ahora explicando porque ocurre que con un ruido ($\|\eta\|_2$) tan pequeño se produce un error tan grande en x_0:

esto de debe a como se amplifica el error: comenzando con el vector $(x_0 - x^*)$ representa el error total de la reconstruccion. Entonces al calcular el producto interno de dicho vector con v_i estamos midiendo cuando de este error se proyecta en la direccion del vector v_i.

Ahora, como parte de la pregunta, se nos pidio mostrar que dicha medicion equivale a $\frac{\langle Av_i, \eta \rangle}{\mu_i}$, como se puede notar, este depende directamente del μ_i el cual si es muy pequeño amplifica la medicion antes mencionada.

Matematicamente podemos notarlo al juntar ambas expreciones que nos quedaron:

Como sabemos que :

$\langle (x_0 - x^*), v_i \rangle = \frac{\langle Av_i, \eta \rangle}{\mu_i}$ y este a su vez cumple con que $\frac{\langle Av_i, \eta \rangle}{\mu_i} \leq \frac{\|\eta\|_2}{\sqrt{\mu_i}}$ entonces podemos deducir que :

$\langle (x_0 - x^*), v_i \rangle \leq \frac{\|\eta\|_2}{\sqrt{\mu_i}}$ y con ello y lo que nos dice el enunciado sobre los valores de η y de μ_i donde si bien el ruido es pequeño, este se ve amplificado por la raiz cuadrada de μ_i y notemos que el enunciado nos dice que $u_{min} = 2 * 10^{-16}$ Entonces eso explica porque el mas minimo ruido η hace la reconstruccion directa entregue una imagen saturada y con una norma absurdamente alta.

(c) Regularización de Tikhonov

i. **Gradiente, Hessiana y único minimizador global.**

Expandiendo la norma,

$$J_\lambda(x) = x^T A^T A x - 2(A^T b)^T x + b^T b + \lambda x^T x,$$

y derivando se obtiene

$$\nabla J_\lambda(x) = 2A^T(Ax - b) + 2\lambda x, \qquad H_{J_\lambda} = 2(A^T A + \lambda I).$$

Para cada vector propio v_i de $A^T A$ se tiene $H_{J_\lambda} v_i = 2(\mu_i + \lambda)v_i$. Como $v_1, \ldots, v_n$ es una base ortonormal de $\mathbb{R}^n$, los valores propios de H_{J_λ} son exactamente $2(\mu_i + \lambda)$. Además,

$$\mu_i = v_i^T A^T A v_i = \|Av_i\|_2^2 \geq 0,$$

por lo que $2(\mu_i + \lambda) \geq 2\lambda > 0$ y H_{J_λ} es definida positiva.

La matriz $A^T A + \lambda I$ tiene valores propios $\mu_i + \lambda > 0$, luego es invertible y la ecuación $\nabla J_\lambda(x) = 0$, es decir $(A^T A + \lambda I)x = A^T b$, tiene como única solución

$$x_\lambda = (A^T A + \lambda I)^{-1} A^T b.$$

Como J_λ es un polinomio de grado 2, su aproximación de Taylor de segundo orden es exacta. Usando $\nabla J_\lambda(x_\lambda) = 0$ y que H_{J_λ} es definida positiva, para todo $y \neq x_\lambda$ resulta

$$J_\lambda(y) - J_\lambda(x_\lambda) = \tfrac{1}{2}(y - x_\lambda)^T H_{J_\lambda}(y - x_\lambda) > 0.$$

Por lo tanto, x_λ es el único minimizador global de J_λ.

ii. **Descomposición de $\langle x_\lambda, v_i \rangle$ y cota del aporte del ruido.**

Tomamos producto interno con v_i en $(A^T A + \lambda I)x_\lambda = A^T b$. Como $A^T A + \lambda I$ es simétrica y v_i es vector propio,

$$(\mu_i + \lambda)\langle x_\lambda, v_i \rangle = \langle A^T b, v_i \rangle = \langle b, Av_i \rangle,$$

donde la última igualdad usa que $\langle u, w \rangle = u^T w$ y que $(A^T b)^T = b^T A$. Reemplazando $b = Ax^* + \eta$ y usando $\langle Ax^*, Av_i \rangle = \langle x^*, A^T A v_i \rangle = \mu_i \langle x^*, v_i \rangle$, se obtiene

$$\langle x_\lambda, v_i \rangle = \frac{\mu_i}{\mu_i + \lambda}\langle x^*, v_i \rangle + \frac{\langle Av_i, \eta \rangle}{\mu_i + \lambda}.$$

Para la cota usamos Cauchy-Schwarz y $\|Av_i\|_2 = \sqrt{\mu_i}$:

$$\left| \frac{\langle Av_i, \eta \rangle}{\mu_i + \lambda} \right| \leq \frac{\sqrt{\mu_i}}{\mu_i + \lambda}\|\eta\|_2 \leq \frac{\|\eta\|_2}{2\sqrt{\lambda}},$$

donde la última desigualdad es la indicación $\mu_i + \lambda \geq 2\sqrt{\mu_i \lambda}$ si $\mu_i > 0$, y es inmediata si $\mu_i = 0$.

Los números $\langle x_\lambda, v_i \rangle$ son las coordenadas de x_λ en la base $v_1, \ldots, v_n$. El primer término depende solo de la imagen verdadera: es la coordenada $\langle x^*, v_i \rangle$ multiplicada por el factor $\mu_i/(\mu_i + \lambda) \in [0, 1)$, y es lo único que quedaría si no hubiera ruido. El segundo depende solo de η y no de x^*, por lo que es el aporte del ruido. A diferencia de (b), donde el error en la dirección v_i solo se podía acotar por $\|\eta\|_2/\sqrt{\mu_i}$, que explota cuando $\mu_i \to 0$, ahora la cota no depende de μ_i.

iii. **Interpretación.**

El comportamiento lo determina el factor $\mu_i/(\mu_i + \lambda)$:

- Si $\mu_i \gg \lambda$, el factor es cercano a 1 y $\langle x_\lambda, v_i \rangle \approx \langle x^*, v_i \rangle + \langle Av_i, \eta \rangle/\mu_i$. La componente de x^* se recupera

casi intacta y el error, acotado por $\|\eta\|_2/\sqrt{\mu_i}$, es pequeño porque μ_i es grande.
- Si $\mu_i \ll \lambda$, el factor es cercano a 0. La componente de x^* se pierde, pero el aporte del ruido también se atenúa, pues está acotado por $\sqrt{\mu_i}\|\eta\|_2/\lambda$.

Así, λ actúa como un umbral: se conservan las direcciones que el desenfoque preserva y se descartan aquellas en las que el ruido dominaría.

Si λ es muy pequeño, casi todos los factores valen 1 y x_λ se aproxima a x_0, con el ruido amplificado en las direcciones de μ_i pequeño. Si λ es muy grande, todos los factores se acercan a 0, por lo que $x_\lambda \to 0$: el ruido desaparece, pero también la imagen, que resulta borrosa y oscura, y el residuo tiende a $\|b\|_2$.

iv. **Implementación.** Los valores se obtienen en la celda de (c) iv del notebook.

	$\|x\|_2$	$\|Ax-b\|_2$
x_0	$3{,}503 \times 10^5$	$6{,}71 \times 10^{-12}$
$\lambda = 10^{-3.5}$	37,06	0,5617
$\lambda = 10^{-2.5}$	36,02	0,6169
$\lambda = 1$	17,18	17,85

Tabla 1: Norma y residuo de cada reconstrucción.

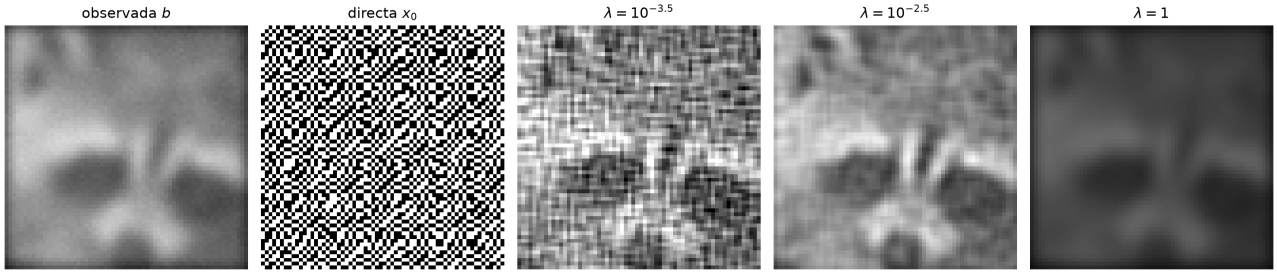


Figura 2: Imagen observada b, solución directa x_0 y reconstrucciones x_λ para $\lambda \in \{10^{-3.5}, 10^{-2.5}, 1\}$.

Como no tiene sentido ajustar b mejor que el tamaño del ruido, comparamos cada residuo con $\delta = 0{,}64$:
- x_0: el residuo es $6{,}71 \times 10^{-12} \ll \delta$, es decir, x_0 ajusta también el ruido. Su norma, $3{,}503 \times 10^5$, es muy superior al máximo posible de 64 y la imagen no contiene información reconocible.
- $\lambda = 10^{-3.5}$: el residuo es $0{,}5617 \approx 0{,}88\,\delta$. La norma ya es razonable y aparece la estructura de la imagen, pero con mucho grano: las direcciones con μ_i cercano a λ siguen dejando pasar ruido, y la cota de (c) ii vale $\delta/(2\sqrt{\lambda}) \approx 18{,}0$. Además, $\max_i |x_i| = 1{,}178$ se sale del intervalo $[0, 1]$.
- $\lambda = 10^{-2.5}$: el residuo es $0{,}6169 \approx 0{,}96\,\delta$, el más cercano a δ. La cota del ruido baja a $\approx 5{,}69$, los valores se mantienen en el rango ($\max_i |x_i| = 0{,}9618$) y la imagen se ve nítida y con poco grano.
- $\lambda = 1$: el residuo es $17{,}85 \approx 27{,}9\,\delta$, muy superior al ruido, por lo que se está regularizando de más. Como $\|Ax\|_2 \le \|x\|_2$, se tiene $\mu_i = \|Av_i\|_2^2 \le 1$, y entonces todos los factores cumplen $\mu_i/(\mu_i + 1) \le 1/2$: incluso las componentes mejor conservadas se reducen a la mitad o menos. Esto explica que la imagen resulte borrosa y oscura, con $\max_i |x_i| = 0{,}4171$.

La mejor reconstrucción de las tres es la de $\lambda = 10^{-2.5}$, que equilibra la imagen recuperada con el ruido admitido, tal como predicen (c) ii y iii.

(d) Píxeles dañados

Sea $\tilde{x}_\lambda = (A^TA + \lambda I)^{-1}A^T\tilde{b}$ la reconstrucción de Tikhonov a partir de $\tilde{b}$.

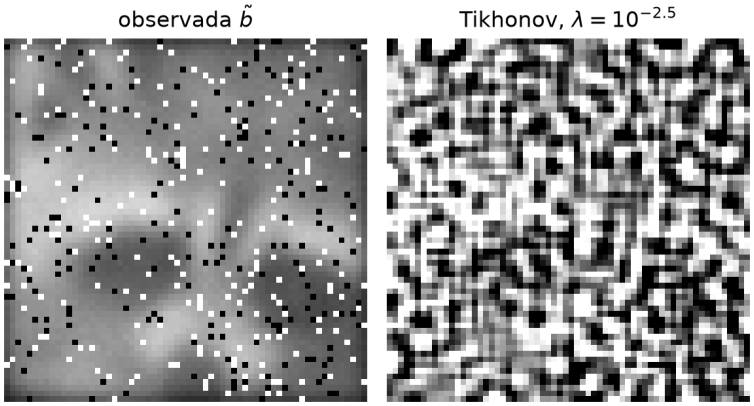


Figura 3: Observación $\tilde{b}$ con píxeles dañados y su reconstrucción de Tikhonov con $\lambda = 10^{-2.5}$.

Con $\lambda = 10^{-2.5}$, la reconstrucción no muestra ninguna estructura reconocible: se obtiene $\|\tilde{x}_\lambda\|_2 = 45{,}91$, $\max_i|\tilde{x}_{\lambda,i}| = 2{,}395$, fuera del intervalo $[0, 1]$, y $\|A\tilde{x}_\lambda - \tilde{b}\|_2 \approx 10$.

i. $\tilde{\eta} = \eta + (\tilde{b} - b)$ **e interpretación de sus sumandos.**

De $\tilde{b} = Ax^* + \tilde{\eta}$ y $Ax^* = b - \eta$ se obtiene

$$\tilde{\eta} = \tilde{b} - Ax^* = \tilde{b} - b + \eta = \eta + (\tilde{b} - b).$$

El sumando η es el ruido habitual del sensor: pequeño y repartido en todos los píxeles, con $\|\eta\|_2 \approx \delta$. El sumando $\tilde{b} - b$ es el error causado por los píxeles dañados: vale cero en los píxeles sanos y, en los dañados, es la diferencia entre la lectura correcta y el valor 0 o 1 que quedó registrado.

ii. $\|\tilde{b} - b\|_2$ **y comparación de** $\|\tilde{\eta}\|_2$ **con** δ**.**

En los datos, 430 de los 4096 píxeles (10,5 %) valen exactamente 0 o 1, y en todos los demás $\tilde{b}$ coincide con b. Se obtiene

$$\|\tilde{b} - b\|_2 = 10{,}74,$$

con diferencias de hasta $0{,}8225$ en un píxel. Como η no se conoce, $\|\tilde{\eta}\|_2$ no se puede calcular de forma exacta, pero la desigualdad triangular aplicada a $\tilde{\eta} = \eta + (\tilde{b} - b)$ y a $\tilde{b} - b = \tilde{\eta} - \eta$, junto con $\|\eta\|_2 \approx \delta$, entrega

$$10{,}10 \lesssim \|\tilde{\eta}\|_2 \lesssim 11{,}38.$$

Es decir, $\|\tilde{\eta}\|_2$ es entre 16 y 18 veces mayor que $\delta = 0{,}64$. El nuevo ruido está dominado por los píxeles dañados.

iii. **¿Por qué fracasa la reconstrucción? ¿Bastaría con aumentar** λ**?**

La deducción de (c) ii solo usa que $\tilde{b} = Ax^* + \tilde{\eta}$, de modo que

$$\langle \tilde{x}_\lambda, v_i\rangle = \frac{\mu_i}{\mu_i + \lambda}\langle x^*, v_i\rangle + \frac{\langle Av_i, \tilde{\eta}\rangle}{\mu_i + \lambda}, \qquad \left|\frac{\langle Av_i, \tilde{\eta}\rangle}{\mu_i + \lambda}\right| \le \frac{\|\tilde{\eta}\|_2}{2\sqrt{\lambda}}.$$

Con $\lambda = 10^{-2.5}$ la cota pasa de $\approx 5{,}69$ a un valor entre 90 y 101. El valor de λ que funcionaba para un ruido de tamaño δ ya no controla un ruido unas 17 veces mayor, y el segundo término pasa a dominar sobre la imagen. Además, J_λ trata todas las lecturas por igual, por lo que no tiene forma de distinguir las lecturas erróneas de las correctas.

Aumentar λ no basta. Para que la cota vuelva a su valor anterior habría que multiplicar λ por $(\|\tilde{\eta}\|_2/\delta)^2 \approx 280$, es decir, llegar a $\lambda \approx 0{,}9$. Eso es prácticamente el caso $\lambda = 1$ de (c) iv, en el que ningún factor $\mu_i/(\mu_i + \lambda)$ supera $1/2$ y la imagen queda borrosa y oscura.

Como x^* no se conoce, en la Tabla 2 usamos como referencia x_λ con $\lambda = 10^{-2.5}$, obtenida desde b en (c) iv. Aumentar λ ayuda solo hasta cierto punto: la distancia a la referencia baja de $28{,}5$ a $8{,}45$ en $\lambda = 10^{-1.5}$, cuyo residuo, $10{,}35$, ya es del orden de $\|\tilde{\eta}\|_2$. Pero esa imagen conserva manchas producidas por los píxeles dañados (Figura 4). Al seguir aumentando λ las manchas se atenúan, pero la distancia vuelve a crecer y la imagen pierde detalle y brillo. Ningún valor de λ probado se acerca a la calidad obtenida sin píxeles dañados, porque λ reduce el ruido y la imagen al mismo tiempo.

	$\|\widetilde{x}_\lambda\|_2$	$\|\widetilde{x}_\lambda - x_{10^{-2.5}}\|_2$	$\|A\widetilde{x}_\lambda - \widetilde{b}\|_2$
$\lambda = 10^{-2.5}$	$45{,}91$	$28{,}5$	$10{,}0$
$\lambda = 10^{-1.5}$	$35{,}61$	$8{,}45$	$10{,}35$
$\lambda = 10^{-0.5}$	$26{,}61$	$10{,}46$	$13{,}73$
$\lambda = 1$	$17{,}16$	$19{,}3$	$20{,}73$

Tabla 2: Reconstrucciones desde $\tilde{b}$ al aumentar λ, comparadas con $x_{10^{-2.5}}$, obtenida desde b.

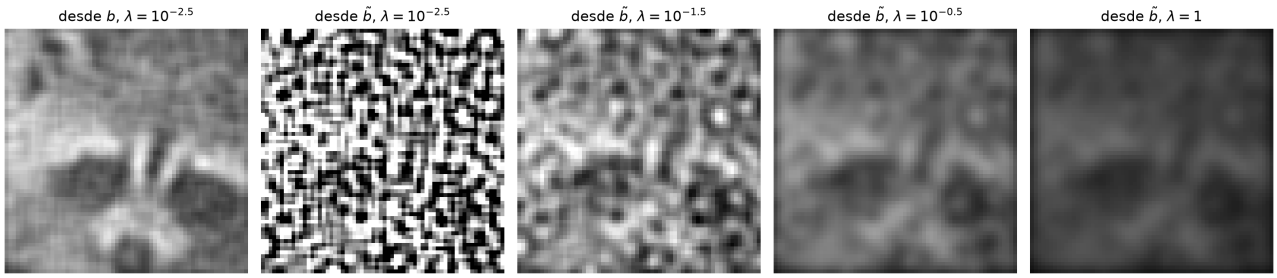


Figura 4: Referencia obtenida desde b y reconstrucciones desde $\tilde{b}$ para valores crecientes de λ.

PROBLEMA 2

Red neuronal con dos capas ocultas

(a) Derivada de la sigmoide

Calculamos la derivada de $\sigma(t)$ usando la regla del cociente:

$$\begin{aligned}\sigma'(t) &= \frac{d}{dt}\left(\frac{1}{1+e^{-t}}\right) = \frac{\frac{d}{dt}(1)\cdot(1+e^{-t}) - (1)\cdot\frac{d}{dt}(1+e^{-t})}{(1+e^{-t})^2} \\ &= \frac{(0)(1+e^{-t}) - (1)\cdot\left(\frac{d}{dt}(1)+\frac{d}{dt}(e^{-t})\right)}{(1+e^{-t})^2} \\ &= \frac{(-1)\cdot\left(0+e^{-t}\cdot\frac{d}{dt}(-t)\right)}{(1+e^{-t})^2} \\ &= \frac{(-1)\cdot\left(e^{-t}\cdot(-1)\right)}{(1+e^{-t})^2} = \frac{e^{-t}}{(1+e^{-t})^2}.\end{aligned}$$

Sumando y restando 1 en el numerador, se obtiene:

$$\begin{aligned}\sigma'(t) &= \frac{1+e^{-t}-1}{(1+e^{-t})^2} = \frac{1+e^{-t}}{(1+e^{-t})^2} - \frac{1}{(1+e^{-t})^2} \\ &= \frac{1}{1+e^{-t}} - \frac{1}{(1+e^{-t})^2} = \frac{1}{1+e^{-t}}\left(1-\frac{1}{1+e^{-t}}\right) \\ &= \sigma(t)\,(1-\sigma(t)).\end{aligned}$$

Dado que la función sigmoide se define como:

$$\sigma(t) = \frac{1}{1+e^{-t}}$$

se cumple $e^{-t} > 0$ para todo $t \in \mathbb{R}$, lo cual implica que:

$$0 < \sigma(t) < 1, \quad \forall t \in \mathbb{R}$$

A partir de $\sigma'(t) = \sigma(t)(1-\sigma(t))$, deducimos directamente que:

$$\sigma'(t) > 0 \quad \forall t \in \mathbb{R}$$

Necesitamos encontrar el valor máximo de $\sigma'(t)$, tal que realizaremos el cambio de variable $u = \sigma(t) \in (0,1)$ y definiremos la función:

$$g(u) = u(1-u) = u - u^2$$

Derivando $g(u)$ con respecto a u e igualando a cero para encontrar sus puntos críticos:

$$g'(u) = 1 - 2u = 0 \implies u = \frac{1}{2}$$

Dado que la segunda derivada de $g(u)$ es $g''(u) = -2 < 0$, el punto $u = 1/2$ corresponde a un máximo global en el intervalo $(0, 1)$. Evaluando $g(u)$ en este punto:

$$g\left(\frac{1}{2}\right) = \frac{1}{2}\left(1 - \frac{1}{2}\right) = \frac{1}{4}$$

Por lo tanto, se concluye que:

$$0 < \sigma'(t) \leq \frac{1}{4} \quad \forall t \in \mathbb{R}$$

Luego, el valor máximo de $\sigma'(t)$ se alcanza cuando $\sigma(t) = \frac{1}{2}$. Resolviendo para t:

$$\sigma(t) = \frac{1}{1+e^{-t}} = \frac{1}{2} \implies 1 + e^{-t} = 2 \implies e^{-t} = 1 \implies t = 0$$

Así, la derivada σ' alcanza su máximo global en $t = 0$, tal que $\sigma'(0) = \frac{1}{4}$.

(b) Función de pérdida y su gradiente

Necesitamos calcular $\nabla_\theta \mathcal{J}(\theta)$, usando el error individual $e_i = \hat{y}_i - y_i$ y siguiendo el camino por el que cada parámetro afecta a $\mathcal{L}_i = \frac{1}{2}e_i^2$ aplicando la regla de la cadena, tenemos:

$$\nabla_\theta \mathcal{J}(\theta) = \frac{1}{N}\sum_{i=1}^{N} \nabla_\theta \mathcal{L}_i(\theta) = \frac{1}{N}\sum_{i=1}^{N} \begin{pmatrix} \dfrac{\partial \mathcal{L}_i}{\partial a_1} \\ \dfrac{\partial \mathcal{L}_i}{\partial b_1} \\ \dfrac{\partial \mathcal{L}_i}{\partial a_2} \\ \dfrac{\partial \mathcal{L}_i}{\partial b_2} \\ \dfrac{\partial \mathcal{L}_i}{\partial v} \\ \dfrac{\partial \mathcal{L}_i}{\partial c} \end{pmatrix}$$

Para cada componente seguimos el camino desde el parámetro hasta $\mathcal{L}_i$:

$$\frac{\partial \mathcal{L}_i}{\partial c} = \frac{\partial \mathcal{L}_i}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial c} = e_i \cdot 1 = e_i$$

$$\frac{\partial \mathcal{L}_i}{\partial v} = \frac{\partial \mathcal{L}_i}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial v} = e_i \cdot h_{2,i}$$

$$\frac{\partial \mathcal{L}_i}{\partial b_2} = \frac{\partial \mathcal{L}_i}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial h_{2,i}} \cdot \frac{\partial h_{2,i}}{\partial z_{2,i}} \cdot \frac{\partial z_{2,i}}{\partial b_2} = e_i \cdot v \cdot \sigma'(z_{2,i}) \cdot 1$$

$$\frac{\partial \mathcal{L}_i}{\partial a_2} = \frac{\partial \mathcal{L}_i}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial h_{2,i}} \cdot \frac{\partial h_{2,i}}{\partial z_{2,i}} \cdot \frac{\partial z_{2,i}}{\partial a_2} = e_i \cdot v \cdot \sigma'(z_{2,i}) \cdot h_{1,i}$$

$$\frac{\partial \mathcal{L}_i}{\partial b_1} = \frac{\partial \mathcal{L}_i}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial h_{2,i}} \cdot \frac{\partial h_{2,i}}{\partial z_{2,i}} \cdot \frac{\partial z_{2,i}}{\partial h_{1,i}} \cdot \frac{\partial h_{1,i}}{\partial z_{1,i}} \cdot \frac{\partial z_{1,i}}{\partial b_1} = e_i \cdot v \cdot \sigma'(z_{2,i}) \cdot a_2 \cdot \sigma'(z_{1,i}) \cdot 1$$

$$\frac{\partial \mathcal{L}_i}{\partial a_1} = \frac{\partial \mathcal{L}_i}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial h_{2,i}} \cdot \frac{\partial h_{2,i}}{\partial z_{2,i}} \cdot \frac{\partial z_{2,i}}{\partial h_{1,i}} \cdot \frac{\partial h_{1,i}}{\partial z_{1,i}} \cdot \frac{\partial z_{1,i}}{\partial a_1} = e_i \cdot v \cdot \sigma'(z_{2,i}) \cdot a_2 \cdot \sigma'(z_{1,i}) \cdot x_i$$

Por lo tanto:

$$\nabla_\theta \mathcal{J}(\theta) = \frac{1}{N} \sum_{i=1}^{N} \begin{pmatrix} e_i \, v \, \sigma'(z_{2,i}) \, a_2 \, \sigma'(z_{1,i}) \, x_i \\ e_i \, v \, \sigma'(z_{2,i}) \, a_2 \, \sigma'(z_{1,i}) \\ e_i \, v \, \sigma'(z_{2,i}) \, h_{1,i} \\ e_i \, v \, \sigma'(z_{2,i}) \\ e_i \, h_{2,i} \\ e_i \end{pmatrix}$$

(c) Implementación y verificación del gradiente

Parámetro	Fórmula de (b)	D_j	Diferencia
a_1	$3{,}17 \times 10^{-4}$	$3{,}17 \times 10^{-4}$	$2{,}72 \times 10^{-12}$
b_1	$-1{,}23 \times 10^{-3}$	$-1{,}23 \times 10^{-3}$	$1{,}31 \times 10^{-11}$
a_2	$-2{,}83 \times 10^{-3}$	$-2{,}83 \times 10^{-3}$	$1{,}74 \times 10^{-11}$
b_2	$-9{,}49 \times 10^{-3}$	$-9{,}49 \times 10^{-3}$	$1{,}38 \times 10^{-11}$
v	$-5{,}95 \times 10^{-1}$	$-5{,}95 \times 10^{-1}$	$8{,}97 \times 10^{-12}$
c	$-1{,}58$	$-1{,}58$	$2{,}79 \times 10^{-12}$

Tabla 3: Gradiente en θ_0: fórmulas de (b) y diferencias centradas.

* -1.58 se obtuvo como -1.58e+00 pero se decidió anotar así en vez de $-1{,}58 \times 10^{0}$

El vector inicial es

$$\theta_0 = (0{,}912;\ -0{,}585;\ 0{,}657;\ -0{,}701;\ 0{,}026;\ -0{,}728), \qquad J(\theta_0) = 1{,}6229.$$

El error máximo entre el gradiente obtenido y las diferencias centradas es

$E = 1{,}74 \times 10^{-11}$.

(d) Descenso del gradiente

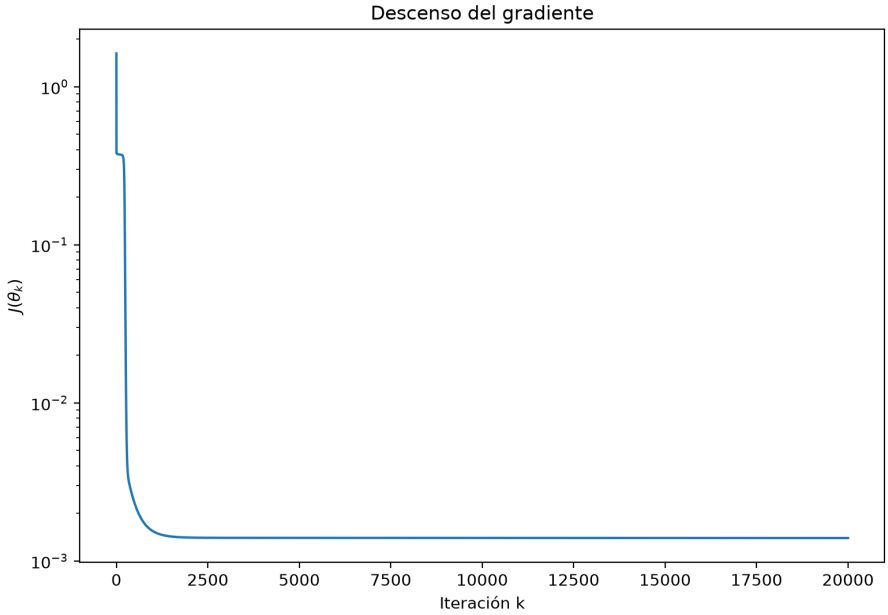


Figura 5: Evolución de $J(\theta_k)$ con $\alpha = 1$.

La Figura 5 muestra $J(\theta_k)$ en escala logarítmica. La pérdida cae rápidamente durante las primeras (aproximadamente) 2000 iteraciones y luego se estabiliza gradualmente, luego de estas iteraciones la curva se vuelve casi lineal, convergiendo a un valor minimo de costo constante.

(e) Parámetros encontrados

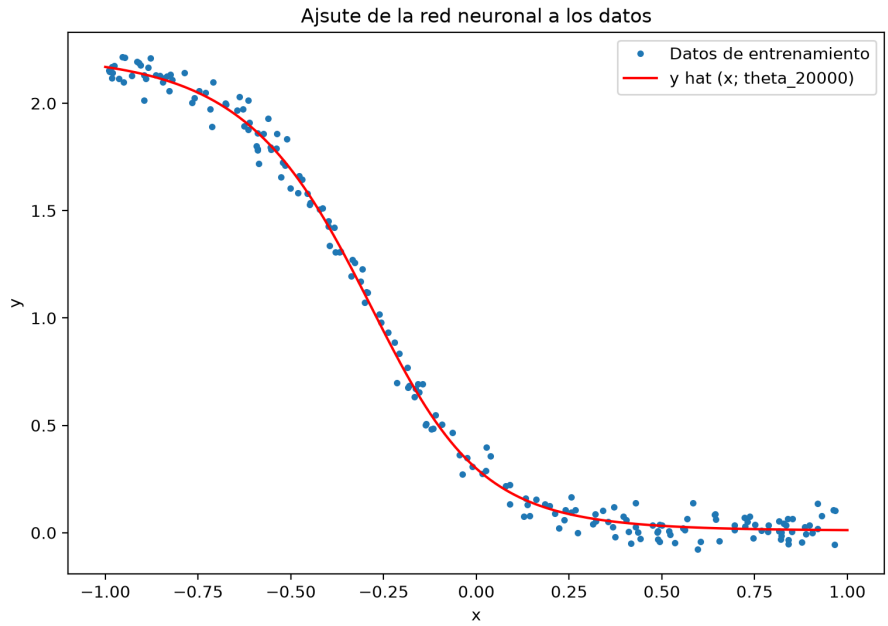


Figura 6: Datos de entrenamiento y curva $x \mapsto \hat{y}(x; \theta_{20.000})$ en $[-1, 1]$.

Tras 20 000 iteraciones con $\alpha = 1$ se obtiene

$$\theta_{20000} = (4{,}623;\ 0{,}718;\ 4{,}394;\ -0{,}990;\ -3{,}178;\ 3{,}086), \qquad J(\theta_{20000}) = 1{,}395 \times 10^{-3}.$$

Como se observa en la Figura 6, la curva $x \mapsto \hat{y}(x; \theta_{20000})$ ajusta bien los datos, siguiendo una forma decreciente que va desde aproximadamente $y = 2.1$, hasta aproximadamente $y = 0$.

(f) Sensibilidad del entrenamiento

i. **Tamaño del paso.**

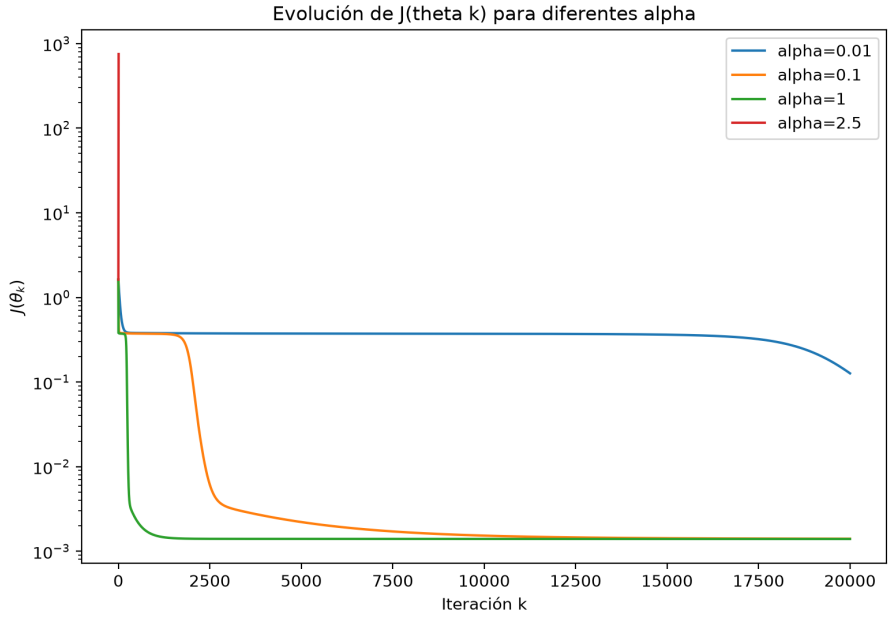


Figura 7: Curvas de error para $\alpha \in \{0{,}01;\ 0{,}1;\ 1;\ 2{,}5\}$, partiendo del mismo θ_0.

Los valores finales de J para cada paso son:

- $\alpha = 0{,}01$: $J_{20000} = 0{,}1265$. El paso es demasiado pequeño, entonces el algoritmo converge muy lentamente y en 20000 iteraciones no alcanza un mínimo de calidad comparable.
- $\alpha = 0{,}1$: $J_{20000} = 1{,}404 \times 10^{-3}$. Converge bien aunque más lento que $\alpha = 1$.
- $\alpha = 1$: $J_{20000} = 1{,}395 \times 10^{-3}$. Es el paso más eficiente, dado que converge rápido y alcanza el menor valor de J.
- $\alpha = 2{,}5$: J deja de ser finito en la iteración $k = 8$. El paso es demasiado grande y en cada actualización los parámetros crecen de manera descontrolada hasta que rapidamente ocurre desbordamiento numérico (*overflow*).

En resumen, un paso muy pequeño ralentiza la convergencia, mientras que un paso excesivamente grande provoca divergencia. El valor $\alpha = 1$ resulta el más adecuado para este problema.

ii. **Distintas inicializaciones.**

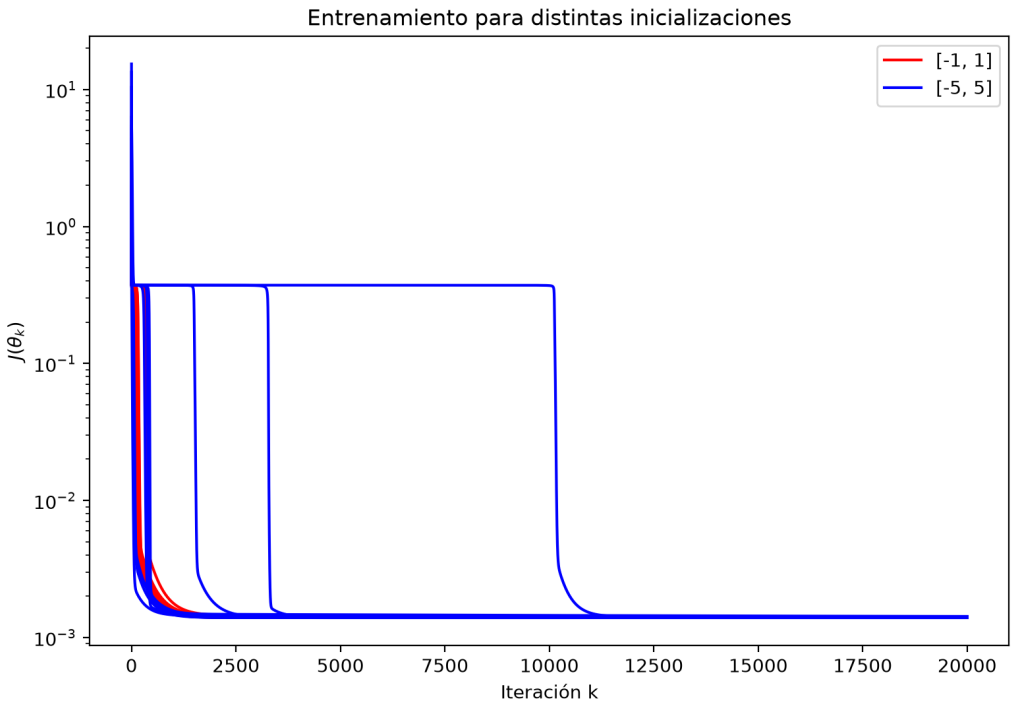


Figura 8: Valores finales de J para 10 inicializaciones con componentes en $[-1, 1]$ y 10 con componentes en $[-5, 5]$.

Con inicializaciones en $[-1, 1]$, las 10 inicializaciones obtienen valores de J finales parecidos, lo que sugiere que el descenso del gradiente encuentra consistentenmente un buen minimo sin importar el punto de partida. En cambio en $[-5, 5]$, algunas inicializaciones quedan atascadas y terminan con valores de J ligeramente superiores al resto. Esto puede deberse a que cuando los parametros iniciales son muy grandes en valor absoluto, los gradientes son casi cero desde el inicio ($\sigma'(t) \approx 0$ cuando $|t|$ es grande), por lo que el algrotitmo logra moverse muy poco apenas con cada iteración, y no logran alejarse del punto de partida desfavorable. Esto también demuestra que el descenso del gradiente no garantiza encontrar el mínimo global, dado que dependiendo del punto de partida, se puede terminar llegando a un minimo local o a una zona plana de la cual es dificil desestancarse.

(g) Datos de otra función

i. **Entrenamiento.**

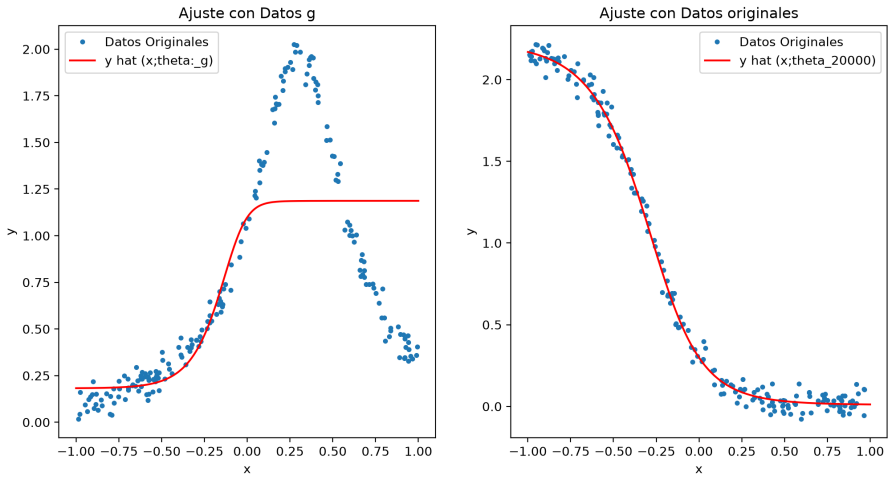


Figura 9: Datos $(x_i, \tilde{y}_i)$ y curva obtenida con la misma red.

Entrenando con `datos_P2_g.csv` desde el mismo θ_0 con $\alpha = 1$ y 20000 iteraciones se obtiene $J = 7{,}822 \times 10^{-2}$, valor considerablemente mayor que el $1{,}395 \times 10^{-3}$ alcanzado con los datos originales. Como muestra la Figura 9, la curva ajustada no logra seguir la forma de los datos $\tilde{y}_i$. Esto se explica en el item siguiente.

ii. **Monotonía, cotas y por qué la red no puede aproximar $\tilde{f}$.**

Calculamos la derivada de $\hat{y}(x;\theta)$ respecto de x aplicando la regla de la cadena:

$$\frac{d\hat{y}}{dx} = v \cdot \sigma'(z_2) \cdot a_2 \cdot \sigma'(z_1) \cdot a_1$$

Como $\sigma'(t) > 0$ para todo $t \in \mathbb{R}$, el signo de $d\hat{y}/dx$ coincide con el de $v \cdot a_1 \cdot a_2$, el cual es constante respecto a x. Por tanto, $x \mapsto \hat{y}(x;\theta)$ es una función **monótona** en $\mathbb{R}$ para cualquier $\theta \in \mathbb{R}^6$ (siendo estrictamente monótona si $v \cdot a_1 \cdot a_2 \neq 0$).

Respecto a las cotas, como $0 < \sigma(t) < 1$ para todo $t \in \mathbb{R}$, se tiene que $0 < h_2 < 1$ y por lo tanto:

$$\hat{y}(x;\theta) = c + vh_2 \in \begin{cases} (c, c+v) & \text{si } v > 0, \\ (c+v, c) & \text{si } v < 0, \\ \{c\} & \text{si } v = 0. \end{cases}$$

Es decir, los valores de $\hat{y}$ están siempre acotados estrictamente entre c y $c + v$.
Observando los datos de `datos_P2_g.csv`, la función $\tilde{f}$ no es monótona, ya que aumenta para $x < 0$ y disminuye para $x > 0$. Dado que toda función representable por esta red es monótona, no existe ningún $\theta \in \mathbb{R}^6$ con el que la red pueda aproximar bien a $\tilde{f}$, sin importar la cantidad de iteraciones, α utilizado, ni la inicialización elegida. La red de una sola neurona por capa oculta restringe el espacio de funciones representables únicamente a las funciones monótonas.