Pontificia Universidad Católica de Chile
Instituto de Ingeniería Matemática y Computacional 2026-2

IMT2220

Cálculo para Ciencia de Datos

Tarea Computacional

Grupo 10

INTEGRANTES
Lucas Martín Chicao Carmona
Ignacio Andrés Osorio Orellana
Martín Ignacio Serrano Pizarro
Martin Antonio Von Gehr Campos

Profesor
Eduardo Cerpa
eduardo.cerpa@uc.cl

Ayudante
Kevin Cardemil
kevin.cardemil@uc.cl

TAREA COMPUTACIONAL

Indicaciones para usar esta plantilla

> **Indicaciones.** Esta plantilla es recomendada para resolver la tarea (aunque pueden utilizar cualquier otro formato mientras cumplan con lo solicitado). Pueden reemplazar cada *[Escriban aquí su desarrollo y su respuesta.]* por su desarrollo. Al final de este archivo hay ejemplos de cómo escribir ecuaciones, incluir figuras y tablas. Borren esa página antes de entregar.

Algunas recomendaciones

- **Desarrollo.** Justifiquen cada paso: no basta con el resultado. Cuando usen un resultado de clases, menciónenlo.
- **Resultados numéricos.** Reporten los valores que se piden (normas, residuos, $J(\theta)$, etc.) con 3 o 4 cifras significativas e indiquen de qué celda del notebook salen. (Esto no es estrictamente necesario, pero sí recomendado.)
- **Figuras.** Guárdenlas desde el notebook con `plt.savefig("figuras/nombre.png", dpi=200, bbox_inches="tight")`, súbanlas a la carpeta `figuras/` (para que puedan añadirlas aquí) y comenten lo que se ve en ellas.

PROBLEMA 1

Reconstrucción de una imagen

(a) Mínimos cuadrados

i. **Gradiente y matriz Hessiana de J_0.**

El enunciado nos dice que consideremos $J_0(x) = \|Ax - b\|_2^2$. Podemos comenzar calculando el gradiente

Asi tenemos lo siguiente:

$J_0(x) = \|Ax - b\|_2^2$ = $(Ax - b)^T * (Ax - b)$ = $(x^T A^T - b^T) * (Ax - b)$ = $x^T A^T Ax - b^T Ax - b^T b$

Ahora como x y b son vectores en R^n (especificamente n x 1, y 1 x n para x^T) y A es n x n podemos notar que $x^T A^T b$ es un escalar ((1 x n) * (n x n) * (n x 1)). Por ende es igual a su transpuesta, asi:

$x^T A^T b = b^T Ax$

Entonces $J_0(x) = x^T A^T Ax - 2b^T Ax + b^T b$

Ahora buscamos el gradiente de la funcion, aplicamos $\nabla J_0(x)$, Derivando cada termino:

- La regla para la siguiente forma $\nabla x(x^T Mx)$ = $(M + M^T)x$

Usando ahora $M = A^T A \rightarrow M^T = A^T (A^T)^T$ = A^T entonces :

$\nabla x(x^T A^T x) = (A^T + A^T) = 2A^T Ax$

-Derivada para $-2(b^T Ax)$, podemos notar que $-2(b^T Ax) = -2(A^T b)^T x$ con ello tenemos la forma $c^T x$; $\nabla x(c^T x) = c$

Entonces :

$\nabla x(-2(A^T b)^T x) = -2(A^T b)$

- Como $b^T b$ No depende de x; $\nabla x(b^T b) = 0$

Asi tenemos que $\nabla x J_0(x)$ = $2A^T Ax - 2A^T b$

Ahora para la Matriz Hessiana se parte del $\nabla J_0(x)$ anterior;

Basicamente debemos calcular $H_{J_0}(x) = \nabla x(\nabla J_0(x))$ asi :

- $\nabla x(2A^T Ax) \rightarrow 2A^T A$ - $-2A^T b$ no tiene un x asi que $\nabla x(-2A^T b) = 0$

Por ende $H_{J_0}(x) = 2A^T A$

Ahora debemos buscar los puntos Criticos y por Teorema de Fernat, el cual nos dice que los puntos criticos de J_0 se encuentran igualando a cero el gradiente.

$\nabla J_0(x) = 0 \Leftrightarrow 2A^T Ax - 2A^T b = 0$ Asi

$A^T Ax = A^T b$

Asi queda demostrado que los puntos criticos de $J_0(x)$ son las ecuaciones normales

$A^T Ax = A^T b$

asd

ii. H_{J_0} **es semidefinida positiva y todo punto crítico es un mínimo global.**

Si todos los valores propios de A^TA son "estrictamente positivos" entonces A^TA es una matriz "Definida positiva"y de rango completo por ende, esta matriz es invertible.

En este caso, el sistema de ecuaciones normales

$A^TAx = A^Tb$ Tiene una unica solucion

$x = (A^TAx)^{-1} * A^Tb$

Por ende J_0 tiene un unico minimizador.

Ahora si A^TA tiene un unico valor propio igual a cero, su determinante es cero haciendo que la matriz no sea invertible.

Ahora digamos que existe un unico vector propio $v \neq 0$ tal que $A^TAv = 0$ (Lo cual implica que Av = 0)

Dado que el sistema de $A^TAx = A^Tb$ siempre mantiene la proyeccion de b, si $< a >$ es un punto critico, cualquier otro punto con la forma $< a + \alpha * v >$ tambien sera una solucion:

$A^TA(\alpha * v) = A^TAxa + \alpha A^TAv = A^Tb + 0 = A^Tb$

Por ende el sistema tiene infinitas soluciones y J_0 tiene infinitos minimizadores.

iii. **Unicidad o infinitos minimizadores.**

Para poder saber si $H_{J_0} = 2A^TA$ es semidefinida positiva ase debe evaluar $\forall v \in \mathbb{R} : v^T * H_{J_0} * v$

Asi para un $v \in \mathbb{R}$:

$v^T(2A^TA)v = 2(Av)^T = 2* \|Av\|_2^2$

y como la norma de cualquier vector es positiva o cero podemos decir que :

$2\|Av\|_2^2 \geq 0$

Por lo tanto H_{J_0} es demidefinida positiva.

Ahora como J_0 es polinomio de grado 2, su aproximacion de taylor de segundo orden es :

$J_0(x + h) = J_0(x) + \nabla J_0(x)^T * h + (h^T * H_{J_0} * h)/2$

si usamos un punto critico tenemos que $\nabla J_0(a) = 0$ asi mismo

$J_0(a + h) = J_0(a) + \nabla J_0(a)^T * h + (h^T * 2A^TA * h)/2$

$J_0(a + h) = J_0(a) + 0 + (h^T * 2A^TA * h)/2$

$J_0(a + h) = J_0(a) + \|Ah\|_2^2$

Como $\|Ah\|_2^2 \geq 0$ para todo h, se puede concluir que $J_0(a + h) \geq J_0(a), \forall h \in \mathbb{R}$.

Asi queda demostrado que a es un minimo absoluto.

.

.

(b) Reconstrucción

i. **Implementación.** Reporten $\|x_0\|_2$, $\max_i |x_{0,i}|$ y $\|Ax_0 - b\|_2$, muestren lado a lado b y x_0, y respondan las preguntas.

Norma ||x0||_2: 350302.18

Máximo absoluto max_i |x0_i|: 1.87e+04

Residuo ||A x0 - b||_2: 5.57e-12

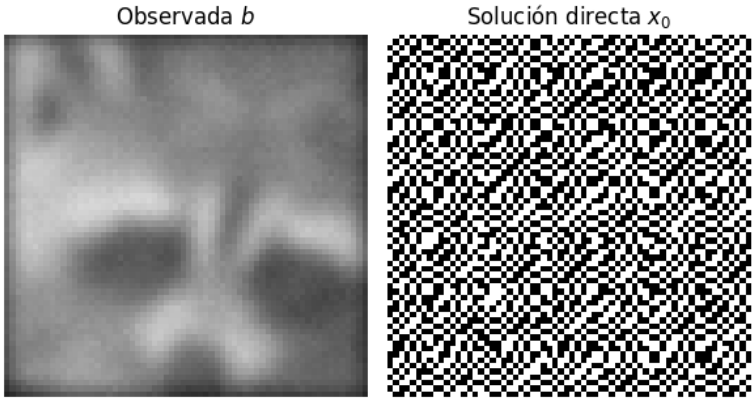


Figura 1: Imagen observada b y solución directa x_0.

La solucion de x_0 No se parece ni de cerca a la imagen de b. Claramente hay mucho ruido y la norma es muchisemo mas grande que el maximo teorico presentado en el enunciado ($n = \sqrt{64}$)

ii. **Explicación.**

Sabemos que por la parte $a)$ de esta pregunta, que el x_0 satisface las ecuaciones normales: $A^T A x_0 = A^T b$

Asi, reemplazando la observacion $b = Ax^* + \eta$ logramos obtener lo siguiente :

$A^T A x_0 = A^T (Ax^* + \eta)$

$A^T A x_0 - A^T A x^* = A^T * \eta$

$A^T A (x_0 - x^*) = A^T * \eta$

Ahora, tomamos el producto interno con el v_i para ambos lados, quedando lo siguiente :

$\langle A^T A (x_0 - x^*), v_i \rangle = \langle A^T \eta, v_i \rangle$

Usando la propiedad de la transpuesta en un producto interno $\langle Mu, w \rangle = \langle u, M^T w \rangle$ y sabiendo que $A^T A$ es simetrica entonces:

$\langle (x_0 - x^*), A^T A v_i \rangle = \langle \eta, A^T v_i \rangle$

Dado que v_i es un vector propio de $A^T A$ con un valor propio de μ_i, sabemos que $A^T A v_i = \mu_i v_i$ y por lo tanto podemos reemplazar

$\langle (x_0 - x^*), \mu_i v_i \rangle = \langle \eta, A^T v_i \rangle$

Por linealidad, sabemos que el escalar sale del producto interno y al divir por μ_i llegamos a lo siguiente:

$\langle (x_0 - x^*), v_i \rangle = \frac{\langle A v_i, \eta \rangle}{\mu_i}$

Ahora partiendo desde ahi, si aplicamos un valor absoluto

$|\langle (x_0 - x^*), v_i \rangle| = |\frac{\langle Av_i, \eta \rangle}{\mu_i}|$

y como por enunciado todo los μ_i son positivos, nos queda lo siguiente:

$\frac{|\langle Av_i, \eta \rangle|}{\mu_i}$

Ahora desde $\langle Av_i, \eta \rangle$ usando la desigualdad de Cauchy-Schwarz tenemos lo siguiente :

$\langle Av_i, \eta \rangle \leq \|Av_i\|_2 \|\eta\|_2$

Para poder calcular el $\|Av_i\|_2$ tenemos que elevarlo al cuadrado y usando las propiedades del producto interno logramos lo siguiente:

$\|Av_i\|_2^2 = \langle Av_i, Av_i \rangle = \langle v_i, A^T Av_i \rangle = \langle v_i, \mu_i v_i \rangle = \mu_i \langle v_i, v_i \rangle = \mu_i \|Av_i\|_2^2$

Ahora dado que los vectores propios v_i son ortonormales, su norma es $\|v_i\|_2 = 1$ Por lo tanto :

$\|Av_i\|_2^2 = \mu_i$

$\|Av_i\|_2 = \sqrt{\mu_i}$

Ahora nomas reemplazamos por lo inicial ($\langle Av_i, \eta \rangle$) y nos queda lo siguiente:

$\langle Av_i, \eta \rangle \leq \sqrt{\mu_i} \|\eta\|_2$

Finalmente solo se tiene que sustituir :

$\langle (x_0 - x^*), v_i \rangle \leq \frac{\sqrt{\mu_i} \|\eta\|_2}{\mu_i}$

$\langle (x_0 - x^*), v_i \rangle \leq \frac{\|\eta\|_2}{\sqrt{\mu_i}}$

Ahora explicando porque ocurre que con un ruido ($\|\eta\|_2$) tan pequeño se produce un error tan grande en x_0:

esto de debe a como se amplifica el error: comenzando con el vector $(x_0 - x^*)$ representa el error total de la reconstruccion. Entonces al calcular el producto interno de dicho vector con v_i estamos midiendo cuando de este error se proyecta en la direccion del vector v_i.

Ahora, como parte de la pregunta, se nos pidio mostrar que dicha medicion equivale a $\frac{\langle Av_i, \eta \rangle}{\mu_i}$, como se puede notar, este depende directamente del μ_i el cual si es muy pequeño amplifica la medicion antes mencionada.

Matematicamente podemos notarlo al juntar ambas expreciones que nos quedaron:

Como sabemos que :

$\langle (x_0 - x^*), v_i \rangle = \frac{\langle Av_i, \eta \rangle}{\mu_i}$ y este a su vez cumple con que $\frac{\langle Av_i, \eta \rangle}{\mu_i} \leq \frac{\|\eta\|_2}{\sqrt{\mu_i}}$ entonces podemos deducir que :

$\langle (x_0 - x^*), v_i \rangle \leq \frac{\|\eta\|_2}{\sqrt{\mu_i}}$ y con ello y lo que nos dice el enunciado sobre los valores de η y de μ_i donde si bien el ruido es pequeño, este se ve amplificado por la raiz cuadrada de μ_i y notemos que el enunciado nos dice que $u_{min} = 2 * 10^{-16}$ Entonces eso explica porque el mas minimo ruido η hace la reconstruccion directa entregue una imagen saturada y con una norma absurdamente alta.

(c) Regularización de Tikhonov

i. **Gradiente, Hessiana y único minimizador global.**

[Escriban aquí su desarrollo y su respuesta.]

ii. **Descomposición de $\langle x_\lambda, v_i \rangle$ y cota del aporte del ruido.**

[Escriban aquí su desarrollo y su respuesta.]

iii. **Interpretación.**

[Escriban aquí su desarrollo y su respuesta.]

iv. **Implementación.** Completen la tabla y comparen las reconstrucciones.

	$\|x\|_2$	$\|Ax - b\|_2$
x_0		
$\lambda = 10^{-3.5}$		
$\lambda = 10^{-2.5}$		
$\lambda = 1$		

Tabla 1: Norma y residuo de cada reconstrucción.

[Falta `figuras/P1_c_tikhonov.png`: se genera al ejecutar el notebook.]

Figura 2: Imagen observada b, solución directa x_0 y reconstrucciones x_λ para $\lambda \in \{10^{-3.5}, 10^{-2.5}, 1\}$.

[Escriban aquí su desarrollo y su respuesta.]

(d) Píxeles dañados

Reconstruyan la imagen a partir de $\tilde{b}$ con $\lambda = 10^{-2.5}$ y muestren lado a lado $\tilde{b}$ y la reconstrucción.

[Falta `figuras/P1_d_danados.png`: se genera al ejecutar el notebook.]

Figura 3: Observación $\tilde{b}$ con píxeles dañados y su reconstrucción de Tikhonov con $\lambda = 10^{-2.5}$.

[Escriban aquí su desarrollo y su respuesta.]

i. **$\tilde{\eta} = \eta + (\tilde{b} - b)$ e interpretación de sus sumandos.**

[Escriban aquí su desarrollo y su respuesta.]

ii. **$\|\tilde{b} - b\|_2$ y comparación de $\|\tilde{\eta}\|_2$ con δ.**

[Escriban aquí su desarrollo y su respuesta.]

iii. **¿Por qué fracasa la reconstrucción? ¿Bastaría con aumentar λ?**

[Escriban aquí su desarrollo y su respuesta.]

(Bonus) Mínimos cuadrados ponderados

[Falta `figuras/P1_bonus_ponderados.png`: se genera al ejecutar el notebook.]

Figura 4: Reconstrucción de Tikhonov a partir de $\tilde{b}$ y reconstrucción con mínimos cuadrados ponderados.

[Escriban aquí su desarrollo y su respuesta.]

PROBLEMA 2

Red neuronal con dos capas ocultas

(a) Derivada de la sigmoide

Calculamos la derivada de $\sigma(t)$ usando la regla del cociente:

$$\begin{aligned}\sigma'(t) &= \frac{d}{dt}\left(\frac{1}{1+e^{-t}}\right) = \frac{\frac{d}{dt}(1)\cdot(1+e^{-t}) - (1)\cdot\frac{d}{dt}(1+e^{-t})}{(1+e^{-t})^2} \\ &= \frac{(0)(1+e^{-t}) - (1)\cdot\left(\frac{d}{dt}(1)+\frac{d}{dt}(e^{-t})\right)}{(1+e^{-t})^2} \\ &= \frac{(-1)\cdot\left(0+e^{-t}\cdot\frac{d}{dt}(-t)\right)}{(1+e^{-t})^2} \\ &= \frac{(-1)\cdot\left(e^{-t}\cdot(-1)\right)}{(1+e^{-t})^2} = \frac{e^{-t}}{(1+e^{-t})^2}.\end{aligned}$$

Sumando y restando 1 en el numerador, se obtiene:

$$\begin{aligned}\sigma'(t) &= \frac{1+e^{-t}-1}{(1+e^{-t})^2} = \frac{1+e^{-t}}{(1+e^{-t})^2} - \frac{1}{(1+e^{-t})^2} \\ &= \frac{1}{1+e^{-t}} - \frac{1}{(1+e^{-t})^2} = \frac{1}{1+e^{-t}}\left(1-\frac{1}{1+e^{-t}}\right) \\ &= \sigma(t)\,(1-\sigma(t)).\end{aligned}$$

Dado que la función sigmoide se define como:

$$\sigma(t) = \frac{1}{1+e^{-t}}$$

se cumple $e^{-t} > 0$ para todo $t \in \mathbb{R}$, lo cual implica que:

$$0 < \sigma(t) < 1, \quad \forall t \in \mathbb{R}$$

A partir de $\sigma'(t) = \sigma(t)(1-\sigma(t))$, deducimos directamente que:

$$\sigma'(t) > 0 \quad \forall t \in \mathbb{R}$$

Necesitamos encontrar el valor máximo de $\sigma'(t)$, tal que realizaremos el cambio de variable $u = \sigma(t) \in (0,1)$ y definiremos la función:

$$g(u) = u(1-u) = u - u^2$$

Derivando $g(u)$ con respecto a u e igualando a cero para encontrar sus puntos críticos:

$$g'(u) = 1 - 2u = 0 \implies u = \frac{1}{2}$$

Dado que la segunda derivada de $g(u)$ es $g''(u) = -2 < 0$, el punto $u = 1/2$ corresponde a un máximo global en el intervalo $(0, 1)$. Evaluando $g(u)$ en este punto:

$$g\left(\frac{1}{2}\right) = \frac{1}{2}\left(1 - \frac{1}{2}\right) = \frac{1}{4}$$

Por lo tanto, se concluye que:

$$0 < \sigma'(t) \leq \frac{1}{4} \quad \forall t \in \mathbb{R}$$

Luego, el valor máximo de $\sigma'(t)$ se alcanza cuando $\sigma(t) = \frac{1}{2}$. Resolviendo para t:

$$\sigma(t) = \frac{1}{1+e^{-t}} = \frac{1}{2} \implies 1 + e^{-t} = 2 \implies e^{-t} = 1 \implies t = 0$$

Así, la derivada σ' alcanza su máximo global en $t = 0$, tal que $\sigma'(0) = \frac{1}{4}$.

[Escriban aquí su desarrollo y su respuesta.]

(b) Función de pérdida y su gradiente

[Escriban aquí su desarrollo y su respuesta.]

(c) Implementación y verificación del gradiente

Reporten θ_0, $J(\theta_0)$ y el error máximo E.

Parámetro	Fórmula de (b)	D_j	Diferencia
a_1			
b_1			
a_2			
b_2			
v			
c			

Tabla 2: Gradiente en θ_0: fórmulas de (b) y diferencias centradas.

[Escriban aquí su desarrollo y su respuesta.]

(d) Descenso del gradiente

[Falta `figuras/P2_d_error.png`: se genera al ejecutar el notebook.]

Figura 5: Evolución de $J(\theta_k)$ con $\alpha = 1$.

[Escriban aquí su desarrollo y su respuesta.]

(e) Parámetros encontrados

Reporten $\theta_{20.000}$ y $J(\theta_{20.000})$.

[Falta `figuras/P2_e_ajuste.png`: se genera al ejecutar el notebook.]

Figura 6: Datos de entrenamiento y curva $x \mapsto \hat{y}(x; \theta_{20.000})$ en $[-1, 1]$.

[Escriban aquí su desarrollo y su respuesta.]

(f) Sensibilidad del entrenamiento

i. **Tamaño del paso.**

[Falta `figuras/P2_f_pasos.png`: se genera al ejecutar el notebook.]

Figura 7: Curvas de error para $\alpha \in \{0{,}01;\ 0{,}1;\ 1;\ 2{,}5\}$, partiendo del mismo θ_0.

[Escriban aquí su desarrollo y su respuesta.]

ii. **Distintas inicializaciones.**

[Falta `figuras/P2_f_inicializaciones.png`: se genera al ejecutar el notebook.]

Figura 8: Valores finales de J para 10 inicializaciones con componentes en $[-1, 1]$ y 10 con componentes en $[-5, 5]$.

[Escriban aquí su desarrollo y su respuesta.]

(g) Datos de otra función

i. **Entrenamiento.**

[Falta `figuras/P2_g_ajuste.png`: se genera al ejecutar el notebook.]

Figura 9: Datos $(x_i, \tilde{y}_i)$ y curva obtenida con la misma red.

[Escriban aquí su desarrollo y su respuesta.]

ii. **Monotonía, cotas y por qué la red no puede aproximar $\tilde{f}$.**

[Escriban aquí su desarrollo y su respuesta.]

TAREA COMPUTACIONAL

Ejemplos de uso (borren esta sección antes de entregar)

Ecuaciones

Una ecuación destacada se escribe entre `\[` y `\]`:

$$\nabla J_0(x) = 2A^T(Ax - b).$$

Para varias líneas alineadas, usen `align*`:

$$\begin{aligned} J_\lambda(x) &= \|Ax - b\|_2^2 + \lambda \|x\|_2^2 \\ &= x^T(A^TA + \lambda I)x - 2(A^Tb)^Tx + b^Tb. \end{aligned}$$

La plantilla define `\norm{x}`, `\abs{x}`, `\ip{u}{v}` (producto interno $\langle u, v \rangle$), `\R` ($\mathbb{R}$) y `\diag`.

Figuras

Guarden la figura desde el notebook en la carpeta `figuras/` e inclúyanla así:

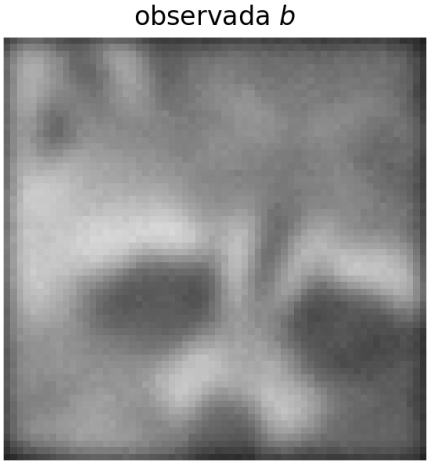


Figura 10: Imagen observada b (ejemplo con los datos de la pauta).

Para referirse a ella, escriban `Figura~\ref{fig:ejemplo}`: Figura 10.

Cajas de comentarios

> **Observación.** Si quieren destacar un comentario, usen el entorno `nota`.